



UTILIZANDO VISÃO
COMPUTACIONAL PARA

Detecção de embarcações na superfície marítima

Lucy K. A. Velasco
IFSP Campus Piracicaba

Tópicos

da apresentação

1. VISÃO GERAL DO PROJETO

2. CONTEXTUALIZAÇÃO

3. ATIVIDADES REALIZADAS

4. RESULTADOS OBTIDOS

Motivação


VISÃO GERAL DO PROJETO



Software para
**detecção de
embarcações** e
evasão de colisões
na **superfície
marítima**

Robôs para coleta
de dados de
qualidade da água
em tempo real de
maneira contínua e
autônoma

Os dados coletados da
água são utilizados
pelo laboratório de
robótica da FIU para
detectar e prever
eventos nocivos na Baía
de Biscayne, na Flórida



Contextualização

SOBRE OS ROBÔS FABRICADOS PELA SEAROBOTICS




Figure 2 Vessel Layout - Aft





Figure 1 Vessel Layout - Forward

Contextualização

SENSORES UTILIZADOS PARA MONITORAR A QUALIDADE DA ÁGUA



○ laboratório utiliza esses sensores para **coletar dados** como:

- temperatura
- condutividade
- pH
- turbidez
- níveis de oxigênio
- entre outros

Esses indicadores permitem antecipar ou detectar na água **eventos catastróficos** que podem causar **morte de peixes** na região.

Um exemplo de anomalia é a **proliferação de algas nocivas**, que pode causar danos ambientais graves, ameaçando a saúde humana através de contaminação de frutos do mar, e impactando negativamente setores econômicos como pesca e turismo.

Atividades realizadas

ETAPAS DO PROJETO



1

Coleta e seleção de um conjunto de imagens contendo embarcações na superfície da água



2

Anotação das imagens marcando regiões onde as embarcações estão presentes



3

Definição das configurações e parâmetros necessários para treinar o modelo YOLO.



4

Treinamento do modelo com base nos dados anotados e nas configurações definidas



5

Testes e validações no modelo para garantir sua eficácia na detecção de embarcações


Etapas iniciais

PRIMEIRAS ATIVIDADES

Coleta e seleção de imagens da base pública Open Image Dataset. Imagens anotadas para detecção, filtradas com a classe barcos.

Treinamento YOLO com 100 épocas e com 200 épocas. mAPs de 49,9% e 66,4%, respectivamente

função de perda com 200 épocas



Tecnologias utilizadas

MATERIAIS E MÉTODOS



Base de dados pública
para embarcações
autônomas, com imagens
capturadas em Boston pelo
Laboratório de Veículos
Subaquáticos Autônomos
(AUV Lab) do MIT.



coleção abrangente de
imagens rotuladas,
amplamente utilizado para
treinar e avaliar modelos
de visão computacional,
abrangendo uma
variedade de objetos em
contextos do mundo real.

Tecnologias utilizadas

MATERIAIS E MÉTODOS



Ferramenta que facilita o uso de visão computacional. Foi utilizada na etapa de anotações e para separar imagens de treino, validação e teste



A versão 8 do modelo de detecção de objetos "You Only Look Once" (YOLO) da Ultralytics foi utilizada para criar, treinar e testar o modelo de detecção




plataforma de nuvem gratuita que oferece recursos de ambiente de execução, incluindo GPU, utilizado para treinamento eficiente de modelos



Python é uma linguagem de programação versátil, que possui sintaxe clara e ampla gama de bibliotecas.

Pesquisas

MATERIAIS E MÉTODOS



Artigos encontrados
principalmente no
IEEEExplore e Google
Scholar



Documentação
oficial da Ultralytics
sobre o YOLOv8



YOLO e o método SGD

- **Gradiente Descendente Estocástico (SGD):** algoritmo de otimização utilizado no treinamento de redes neurais, ajustando iterativamente os pesos em direção à minimização da função de perda com amostras aleatórias do conjunto de treinamento, sendo controlado pela taxa de aprendizado.
- **Taxa de aprendizado:** é um hiperparâmetro que controla o tamanho dos ajustes nos pesos durante o treinamento de redes neurais, afetando a rapidez com que o modelo converge para uma solução.



parâmetro	valor	descrição
epochs	200	Número de épocas ou iterações completas através do conjunto de dados durante o treinamento.
patience	50	O treinamento é interrompido se a performance não melhorar após 50 iterações consecutivas.
optimizer	"AdamW"	Otimizador usado para ajustar os pesos do modelo durante o treinamento



Resultados

MÉTRICAS

A função de perda avalia o quão distantes as previsões do modelo estão dos resultados reais durante o treinamento, enquanto a métrica mAP mede a precisão média das detecções

A estabilidade e convergência dessas curvas são cruciais para garantir a eficácia das detecções.

- mAP final (precisão média) = 85,64%



Resultados

VALIDAÇÃO DO MODELO

A figura ao lado exibe as predições do modelo em um conjunto de validação, destacando as detecções e as caixas delimitadoras, acompanhadas de um número que indica a confiança do modelo de que aquela região específica contém uma embarcação




Resultados



DEMONSTRAÇÃO

<https://www.youtube.com/watch?v=OVeHsuO8Wrc>



GITHUB

<https://github.com/arguejadalucy/boat-detector>



ROBOFLOW

<https://universe.roboflow.com/wsod/water-surface-object-detection>

Referências bibliográficas

DEFILIPPO, M.; SACARNY, M.; ROBINETTE, P. AUTONOMOUS UNDERWATER VEHICLES LABORATORY (AUV LAB): MIT SEA GRANT MARINE PERCEPTION DATASET. 2021. DISPONÍVEL EM: <[HTTPS://SEAGRANT.MIT.EDU/AUVLAB-DATASETS-MARINE-PERCEPTION-1/](https://seagrants.mit.edu/auvlab-datasets-marine-perception-1/)>. ACESSO EM: 27.09.2023.

GAŠPAROVIC, B.; MAUŠA, G.; RUKAVINA, C. J.; LERGA, J. EVALUATING YOLOV5, YOLOV6, YOLOV7, AND YOLOV8 IN UNDERWATER ENVIRONMENT: IS THERE REAL IMPROVEMENT? INTERNATIONAL CONFERENCE ON SMART AND SUSTAINABLE TECHNOLOGIES (SPLITECH), INSTITUTE OF ELECTRICAL AND ELECTRONICS ENGINEERS INC., 2023.

JOCHER, G.; CHAURASIA, A.; QIU, J. YOLO BY ULTRALYTICS (VERSION 8.0). 2023.

DISPONÍVEL EM: <[HTTPS://GITHUB.COM/ULTRALYTICS/ULTRALYTICS](https://github.com/ultralytics/ultralytics)>. ACESSO EM: 27.09.2023.

PADRAO, P.; DOMINGUEZ, A.; BOBADILLA, L.; SMITH, R. N. TOWARDS LEARNING OCEAN MODELS FOR LONG-TERM NAVIGATION IN DYNAMIC ENVIRONMENTS. IN: IEEE. OCEANS 2022- CHENNAI. [S.L.], 2022. P. 1-6.

PRASAD, D. K.; DONG, H.; RAJAN, D.; QUEK, C. ARE OBJECT DETECTION ASSESSMENT CRITERIA READY FOR MARITIME COMPUTER VISION? IEEE TRANSACTIONS ON INTELLIGENT TRANSPORTATION SYSTEMS, INSTITUTE OF ELECTRICAL AND ELECTRONICS ENGINEERS INC., V. 21, P. 5295-5304, 12 2020. ISSN 15580016.

SEAROBOTICS. SR-SURVEYOR M1.8. 2020. DISPONÍVEL EM: <[HTTPS://WWW.SEAROBOTICS.COM/PRODUCTS/AUTONOMOUS-SURFACE-VEHICLES/SR-SURVEYOR-M1-8](https://www.searobotics.com/products/autonomous-surface-vehicles/sr-surveyor-m1-8)>. ACESSO EM: 27.09.2023.

SÁ, T. R. D.; FIGUEIREDO, C. M. S. VISTA DO SELF-DRIVING VESSELS YOLOV5 APPROACH FOR WATER SURFACE OBJECT DETECTION. SIMPÓSIO BRASILEIRO DE COMPUTAÇÃO UBÍQUA E PERVASIVA (SBCUP), 2022.



Q&A

Obrigada!



PERGUNTAS?